Хеш таблицы

Составитель: Рощупкин Александр

Хеширующие таблицы

Определение

* **Хеш-таблица (hash table)** – структура данных для хранения пар «ключ – значение»
* Доступ к элементам осуществляется по ключу (key)
* Ключи могут быть любыми объектами - строками, числами и т.д.
* Хеш-таблицы позволяют в среднем за время O(1) выполнять добавление, поиски и удаление элементов

Пример аутентификации

* Необходимо написать класс, который определяет правильность введения пары – логин, пароль

Принцип работы хеш таблицы

* Обычные массивы хороши тем, что у них быстрый доступ по ключу (индексу)
* Недостаток массивов – ключами (индексами) могут быть только целые числа
* Хеш таблица позволяет использовать массив для хранения объектов и в качестве ключей (индексов) использовать любые типы данных
* Для преобразования объекта в индекс используется принцип хеширования

Понятие хеширования

* **Хеширование** – алгоритм преобразующий набор данных любой длинны в набор данных фиксированной длинны
* **Хеш функция** – это метод, преобразующий ключ (объект) в номер элемента массива
* **Хеш код** – результат работы хеш функции

Вычисление хеш кода

* Вычислением хеш кода для любого объекта занимается метод hashCode() находящийся в классе Object
* Значение хеш кода должно зависеть от значения всех данных объекта
* К примеру можно вычислить циклическую сумму целочисленных значений всех полей

Значения хеш кода

* Для одного и того же объекта значение хеш-кода должно быть всегда одинаково

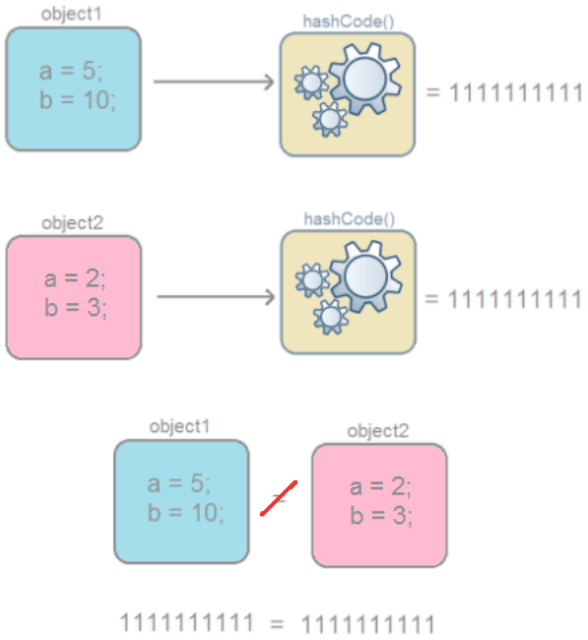

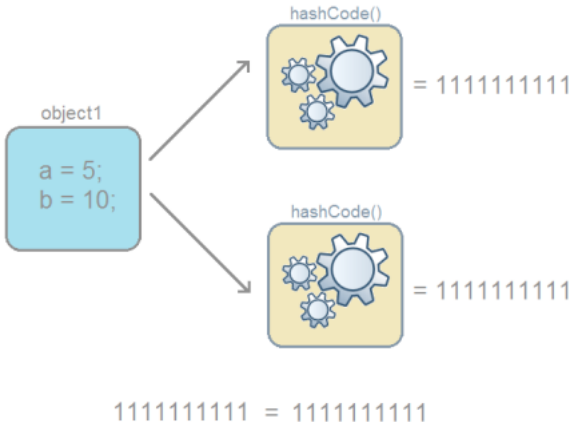

* Если объекты одинаковые, то и хеш-коды одинаковые

Метод hashCode из Object

```
public native int hashCode();
```

* Ключевое слово native означает, что реализация данного метода выполнена на другом языке, например на C, C++ или ассемблере. Конкретный native int hashCode() реализован на C++
* Для вычисления хеш-кода используется Park-Miller RNG алгоритм, в основе которого лежит генерация случайных чисел
* Хеш-код для объекта вычисляется при первом вызове и затем помещается в объекта и возвращается при каждом вызове метода hashCode()

Метод equals

* Для проверки эквивалентности в классе Object существует метод equals(), который сравнивает содержимое объектов и выводит значение типа boolean true, если содержимое эквивалентно, и false — если нет
* Не переопределённый метод equals сравнивает значение ссылок

```
public boolean equals(Object obj) {
    return (this == obj)
}
```

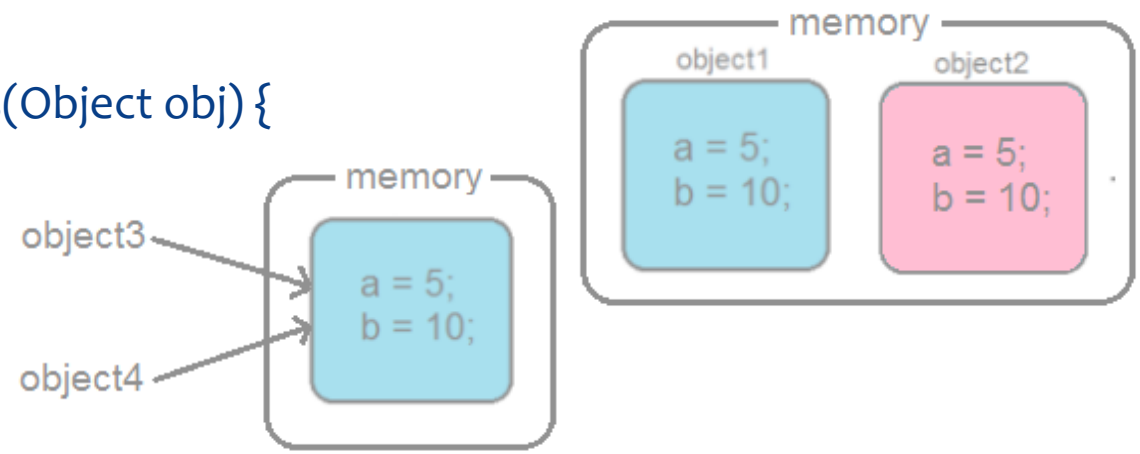

Контракт equals и hashCode

* Эквивалентность и хеш-код тесно связанны между собой, поскольку хеш-код вычисляется на основании содержимого объекта (значения полей) и если у двух объектов одного и того же класса содержимое одинаковое, то и хеш-коды должны быть одинаковые

```
object1.equals(object2) // должно быть true
object1.hashCode() == object2.hashCode() // должно быть true
```

Коллизии

* Ситуация при которой у разных объектов хеш коды одинаковы называется колизией
* Методы решения колизий:
  * Открытая адресация
  * Метод цепочек

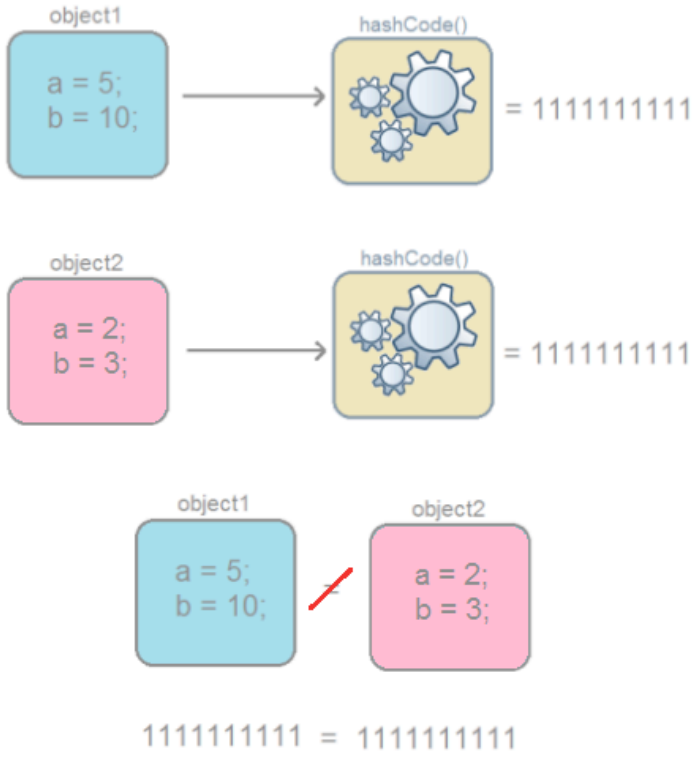

Линейное зондирование

* Метод открытой адресации состоит в том, чтобы, пользуясь каким-либо алгоритмом, обеспечивающим перебор элементов таблицы, просматривать их в поисках свободного места для новой записи
* Линейное опробование сводится к последовательному перебору элементов таблицы с некоторым фиксированным шагом

  $a=h(key) + c*i$
* При достижении конца таблицы осуществляется переход в начало

Домашнее задание

* Написать собственную реализацию хеш-таблицы с решением коллизий методом линейного зондирования. Реализовать методы put, get, delete
* Добавить в реализацию хеш-таблицы поддержку дженериков

Метод цепочек

* Объекты с одинаковыми хеш-кодами помещаются в одну ячейку (корзину) в виде связанного списка и затем сравниваются методом equals

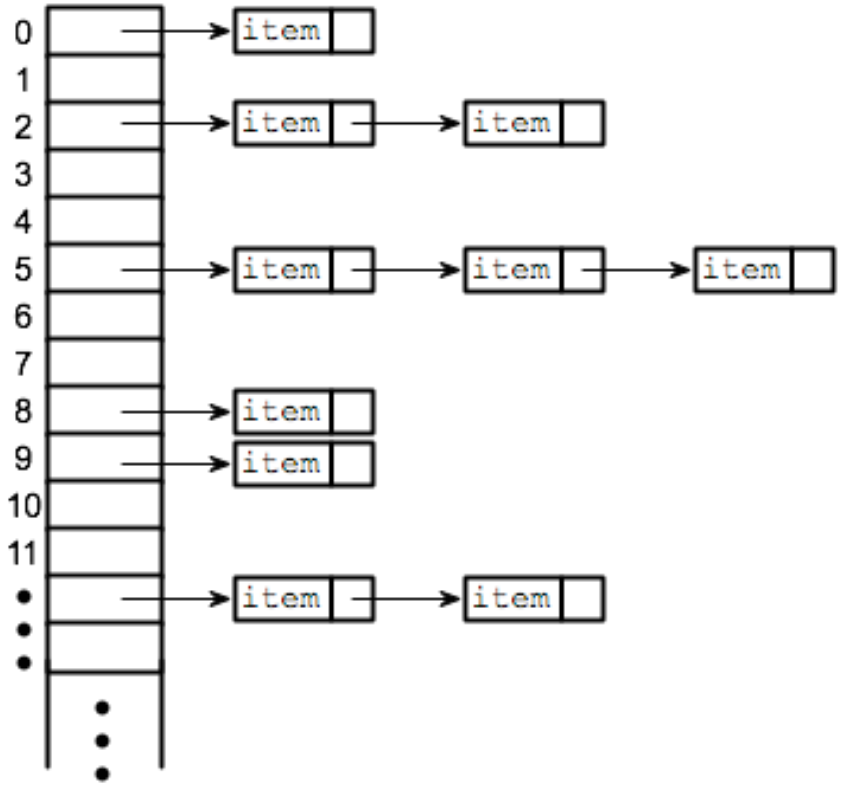

Пример узла для метода цепочек

* Можно сделать наследника класса Entry, в который добавить ссылки на следующий элемент одно-связанного списка
* При добавлении элемента необходимо пройти оп списку и проверить наличие добавляемого элемента в списке
* Если элемент есть, добавлять не надо, если нет ещё такого элемента, то надо добавить в конец списка

Правильный хеш-код

* **Равномерность (uniform distribution)** – хеш-функция должна равномерно заполнять индексы массива возвращаемыми номерами
* Желательно, чтобы все хэш-коды формировались с одинаковой равномерно распределенной вероятностью

Неправильный хеш код

* Постоянное число
* Случайное число

Load factor

* Load factor - коэффициент заполнения хеш-таблицы
* Отношение числа n хранимых элементов в хеш-таблице к размеру h массива
* По коэффициенту заполнения можно принимать решение об изменении размера хеш-таблицы
* Для изменения размера нужно:
  * Создать новый массив
  * Перекопировать элементы с повторным хешированием

Замена связанного списка AVL деревом

* Если количество коллизий в рамках одного бакета стало больше 8, то эффективнее заменить связанный список на АВЛ дерево
* При этом сложность поиска элемента в бакете станет не линейным а логорифмическим
* Для замены списка деревом можно сделать класс узла дерева, наследоваться от класса узла списка и добавить ссылку на левого потомка
* Ссылку на следующий элемент можно использовать как ссылку на правого потомка